

# **Caracterización de plantaciones forestales a partir de información derivada de plataformas satelitales y servicios de procesamiento de datos en la nube**

A mediados de la década del '90, en el ámbito de la Dirección de Producción Forestal (DPF) del Ministerio se conforma el Área SIG e Inventario Forestal cuyo objetivo principal fuera el de cartografiar y monitorear los rodales forestales en todo el territorio nacional, utilizando técnicas de teledetección y SIG. La incorporación progresiva de nuevas herramientas tecnológicas posibilitó a la DPF gestionar eficazmente la operatoria de la ley 25.080 de Inversiones para Bosques Cultivados, generando la cartografía de las plantaciones forestales. En el campo de la teledetección, históricamente la DPF ha utilizado la técnica de la interpretación visual de imágenes satelitales. Esta técnica consiste en analizar, determinados patrones presentes en las imágenes para posteriormente digitalizar en forma manual los rodales. Se han empleado con el correr de los años distintas colecciones de imágenes satelitales, correspondientes a las plataformas Landsat 5/7, Spot 4/5/6/7, CBERS, fotografías aéreas y Sentinel 2. Sin embargo existen muchas experiencias donde se utiliza la información espectral para estimar y cuantificar las variables de estado estructurales de los bosques (Kangas, et al., 2018), así como para identificar especies forestales y analizar la evolución a través del tiempo (TrendsEarth, 2018) (Kennedy, et al., 2018), información muy valiosa a la hora de caracterizar las masas forestales y la dinámica de acumulación de biomasa forestal aérea (AGB). Muchos investigadores han empleado a la serie temporal Landsat (LTS) para estimar la AGB, posiblemente debido a las características de las plataformas, la política de datos abiertos y gratuitidad a partir de 2008 (Woodcock, et al. 2008). Debido a su resolución espacial y temporal la serie Landsat ha sido utilizada exhaustivamente para el monitoreo forestal en relación a eventos naturales y antropogénicos desde el año 1972. (Nguyen, et al. 2020). Ahl et al. (2006), Urbazaev et al. (2016), Hansen et al. (2013), han empleado estos recursos para caracterizar y cuantificar los cambios en los bosques a escala global, a partir de datos de la serie Landsat. Hall et al. (2006) han evaluado y derivado (AGB) correlacionando datos espectrales (Landsat) con los obtenidos a partir de inventarios forestales. Hansen et al. (2016) han utilizado esta plataforma para calibrar modelos sobre la base de datos Landsat OLI para estimar la altura en África Subsahariana.

## **1. Monitoreo de cambios**

### **Estimación de la precisión del producto cartográfico GFC en la detección de cosecha en plantaciones forestales de la región Nordeste de Argentina**

#### **Introducción**

Las técnicas de percepción remota satelital han sido ampliamente utilizadas para el mapeo, identificación y evaluación de la cobertura terrestre de forma sistemática y costo efectiva, en una amplia variedad de extensiones espaciales (Gómez, et al. 2016). El incremento en la disponibilidad de datos de observación de la Tierra, particularmente del archivo Landsat, ha sido uno de los principales catalizadores de la mejora en la capacidad de monitoreo de la cobertura terrestre (Galiatsatos, et al. 2020; Gómez, et al. 2016). Este cambió posibilitó la creación de múltiples y variados mapas globales y regionales de cobertura de la tierra, entre los cuales se distingue el producto cartográfico de detección de Cambio Global Forestal (GFC, por sus siglas en inglés), desarrollado por Hansen et al. (2013). Este producto es generado a partir del procesamiento de una serie temporal de imágenes Landsat, a una resolución de 30 metros, y se compone de tres mapas con información referida a: (1) porcentaje de cobertura arbórea en el año 2000, (2) ganancia de cobertura forestal en el período 2000-2012 y (3) pérdida de cobertura forestal anual. Este último mapa permite contabilizar el área de pérdida forestal para cada año, a

través de una serie de cálculos basados en valores del Índice de Vegetación de Diferencia Normalizada (NDVI) y porcentaje de cobertura arbórea.

Los mapas de Cambio Global Forestal de Hansen et al., (2013) se han convertido en una de las herramientas más utilizadas en estudios de cobertura forestal (Hansen, et al. 2013), deforestación (Richard & Friess, 2015; Curtis, et al. 2018), fragmentación (Taubert, et al. 2018) y técnicas de manejo forestal (Santika, et al. 2017), entre otros. Sin embargo, no se encuentra exenta de limitaciones. Por un lado, para su construcción emplea una definición de bosque referida únicamente a cobertura arbórea, clasificando como bosque a toda vegetación con una altura mayor a 5 metros. Esta definición determina que las áreas forestales detectadas por el producto GFC sean en muchos casos sobreestimadas, dado que no tiene en cuenta el tipo de uso de la tierra de la cobertura arbórea detectada (Lwin, et al. 2019; Tropek, et al. 2014). En relación a esto, se observaron sobreestimaciones del producto, al clasificar áreas de múltiples tipos de cultivo (banana, café, azúcar, palma aceitera) como bosque (Tropék, et al. 2014; Cunningham, et al. 2019).

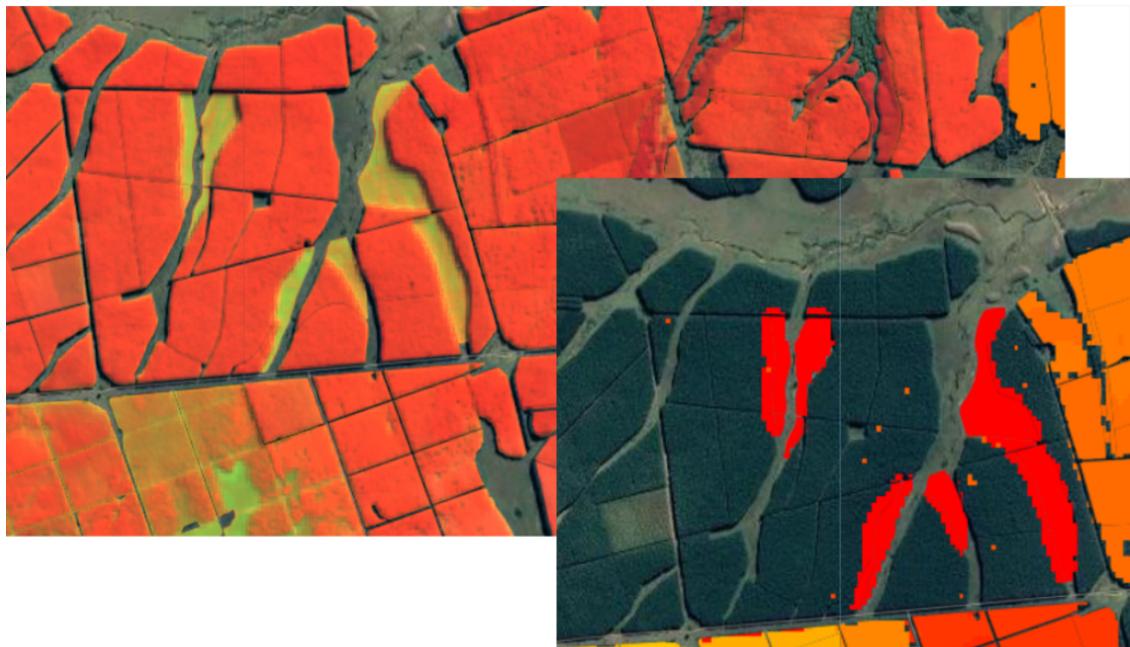
En adición, Cunningham et al., (2019) identificaron imprecisiones del mapa de cobertura arbórea del producto a lo largo de gradientes de precipitación y elevación. Resultados obtenidos en varios estudios (Cunningham et al., 2019; Hojas-Gascon et al., 2015; Sannier et al., 2015) sugieren que el producto GFC tiende a sobreestimar las áreas de bosque en ecoregiones húmedas y subestimar la cobertura arbórea en ecoregiones secas. En cuanto al sesgo debido a la elevación, este podría deberse a la contaminación de las imágenes satelitales empleadas en la clasificación, con factores como sombras del terreno, nubosidad persistente a gran altura, sombras de nubes o nubes semitransparentes (Zhu & Woodcock, 2012; Qiu, et al., 2017; Li, et al., 2012; Asner, 2001).

Por otra parte, resultados reportados en distintos estudios indican que los mapas de GFC subestiman las áreas de ganancia de cobertura forestal (Guindon et al. 2018; Li et al. 2017; Sannier et al. 2015). Guindon et al. (2017) encontraron una menor precisión del producto a la hora de detectar áreas de recuperación de cobertura forestal, luego de haber sido afectadas por incendios y la dinámica de la actividad forestal. De acuerdo con Li et al. (2017), esta menor precisión de las estimaciones de ganancia forestal podría reflejar el hecho de que el crecimiento forestal es un proceso ecológico paulatino y complejo, que se manifiesta con una señal gradual más difícil de detectar que la pérdida de bosques, que generalmente se identifica como una señal abrupta. En coincidencia con esto, Arjasakusuma et al. (2018) encontraron que las estimaciones de pérdida de bosque del producto fueron significativamente mayores a las obtenidas a partir de otros métodos de estimación de cambio forestal. Según estos autores, esta diferencia puede ser atribuida al cálculo agregado de pérdida forestal durante una serie de años, lo cual determina que el producto GFC no disponga de información precisa acerca del año de “revegetación” de las áreas de pérdida de bosque acumuladas en el período. Estos resultados sugieren una menor capacidad de detectar ganancia forestal por parte del producto GFC, lo cual se traduciría en sobreestimaciones en los valores de pérdida de cobertura forestal.

Los mapas desarrollados por Hansen et al. (2013) representan un avance importante en la comprensión y cuantificación del cambio forestal global. Sin embargo, es fundamental conocer sus limitaciones y fuentes de sesgo dentro de los distintos tipos de bosques a fin de garantizar su uso apropiado en aplicaciones específicas y contextos locales (Mitchard, et al. 2015). En este sentido, Hansen et al. (2014) recomiendan utilizar el producto GFC de forma integrada con fuentes de información adicionales, como tipos de bosque, uso de la tierra y áreas protegidas, provenientes de bases de datos locales.

En este contexto se desarrolla el presente trabajo, cuyo objetivo es evaluar la precisión del producto GFC en la detección de pérdida forestal (cosecha) durante el año 2019 en plantaciones

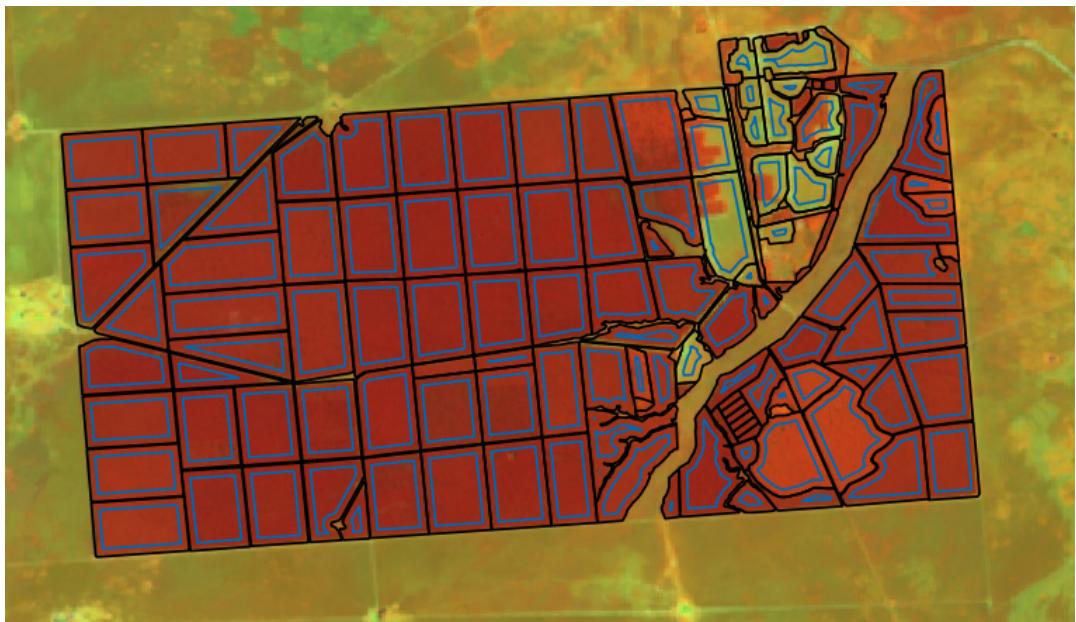
forestales de las provincias de Corrientes, Entre Ríos y Misiones. La capa de pérdida de cobertura forestal del producto será empleada posteriormente para obtener estimaciones del área cosechada de las plantaciones en Argentina durante el período 2000-2019 (Figura 1), por lo que, mediante este estudio se espera generar una medida del error de estas estimaciones.



**Figura 1.** Cartografía de Cosechas forestales. En color rojo se identifican las áreas de cambio correspondientes al año 2019 de acuerdo al producto Cambio Forestal Global (Hansen, et al. 2013).

## Materiales y Métodos

En una primera instancia, en el software QGIS se realizó la conversión del producto GFC de pérdida de cobertura forestal en el año 2019 desde un formato ráster a un formato vectorial. Luego, a fin de circunscribir el análisis a las plantaciones forestales de la región de estudio, en QGIS se realizó la intersección del producto GFC con la cartografía de macizos forestales de las provincias de Corrientes, Entre Ríos y Misiones. Previo a la intersección, a esta última se le generó en Qgis una zona de influencia negativa (buffer) de aproximadamente 60 metros, con el objeto de eliminar el efecto de bordura de las plantaciones (Álvarez, 2018; Harper, et al. 2005) (Figura 2). Este procedimiento permitió generar una nueva capa vectorial de polígonos de pérdida forestal en 2019 detectados exclusivamente en plantaciones forestales de las mencionadas provincias. Esta capa fue utilizada posteriormente para evaluar la precisión del producto en la detección de cosechas forestales.



**Figura 2.** Detalle de la cartografía de macizos forestales. En color negro se observan los límites de la capa vectorial de macizos forestales, en color azul el buffer generado sobre la cartografía de las plantaciones.

### Diseño de muestreo

La evaluación de la precisión del producto se realizó en base a un muestreo aleatorio estratificado, estando las unidades muestrales o puntos de control representados por los polígonos de pérdida de cobertura forestal en 2019 del producto GFC. Los criterios empleados para la estratificación fueron género y año de plantación. Los géneros incluidos fueron Eucalyptus, Pinus y un grupo denominado Otros, que abarca géneros como Toona y Tabebuia en la provincia de Corrientes, Salix y Populus en la de Entre Ríos y Araucaria y Grevillea en Misiones. En cuanto al año de plantación, se conformaron 3 clases de edad, denominadas C1, C2 y C3, que incluyen macizos con años de plantación posteriores al 2011, entre los años 2009 y 2011 y anteriores al 2009, respectivamente. Por otra parte, aquellos polígonos de los cuales no se disponía de información acerca del género o año de plantación fueron asignados a un estrato llamado “Sin datos”. De esta manera, los estratos a muestrear fueron los siguientes:

Género	Clase de edad	Año de plantación	Estrato
Eucalyptus	C1	> 2011	Eucalyptus C1
Eucalyptus	C2	2009-2011	Eucalyptus C2
Eucalyptus	C3	<2009	Eucalyptus C3
Pinus	C1	> 2011	Pinus C1
Pinus	C2	2009-2011	Pinus C2
Pinus	C3	<2009	Pinus C3
Otros	C1	> 2011	Otros C1
Otros	C2	2009-2011	Otros C2
Otros	C3	<2009	Otros C3
Sin datos	-	Sin datos-	Sin datos

Una vez conformados los estratos, en QGIS los polígonos de la capa vectorial de pérdida forestal en 2019 fueron seleccionados en base a su superficie, de forma que la muestra a analizar en cada estrato estuviera constituida únicamente por polígonos con una superficie mayor o igual a 0,25 hectáreas. Los polígonos fueron considerados equivalentes, independientemente de su tamaño.

El tamaño óptimo de muestra se calculó en base a la fórmula de Cochran (1977), asumiendo igual variabilidad entre estratos:

$$n = \frac{Z^2 pq}{d^2}$$

En donde:  $Z$  es el valor de la función de distribución Normal acumulada para un área  $(1-\alpha)/2$ ,  $p$  la proporción estimada de una determinada clase en la población,  $d$  el nivel deseado de precisión y  $q$  el complemento de  $p$ , siendo  $(1 - p)$ .

Para el cálculo del tamaño muestral, se empleó un valor  $Z$  correspondiente a un nivel de confianza del 95% y un nivel de precisión del 5%. En cuanto a la proporción  $p$ , en este análisis de verificación, la misma representa la proporción estimada de pérdida de cobertura forestal según el producto GFC. A esta se le asignó un valor de 0.5, el cual permite obtener el máximo tamaño muestral para los niveles de precisión y confianza utilizados (Boca & Rodriguez, 2012). A su vez, el tamaño muestral calculado fue corregido según la fórmula de Cochran (1977), que ajusta el número de polígonos a muestrear en base al total poblacional;

$$n = \frac{n_0}{1 + (n_0 - 1/N)}$$

Siendo  $n_0$  el tamaño muestral para poblaciones infinitas y  $N$  el tamaño de la población de referencia.

El tamaño muestral total fue distribuido entre estratos en base a una afijación proporcional. Por último, la selección aleatoria de los polígonos en cada estrato se realizó a partir de las herramientas para capas vectoriales de QGIS.

## Verificación

La evaluación de la precisión del producto en la detección de cosechas se realizó en QGIS a través de la interpretación visual de imágenes Sentinel 2, correspondientes al inicio de los años 2019 y 2020, a fin de corroborar que efectivamente se produjo un cambio por cosecha en las plantaciones durante el año 2019. La detección de cosecha por parte del producto fue calificada como correcta cuando a comienzos del año 2019, el macizo forestal sobre el cual se localizó el polígono de pérdida se observaba en pie y hacia comienzos del 2020 se encontraba cosechado (sin cobertura forestal). En adición, como fuente auxiliar para la verificación de cosecha, se emplearon imágenes de alta resolución de la plataforma Google Earth.

Los datos de la validación de la detección de cosecha fueron registrados en una planilla para su posterior procesamiento en el software RStudio. En este último, se realizó el conteo de polígonos de cosecha correctamente detectados por el producto para luego realizar el cálculo de su precisión global y la precisión según estrato, estando la precisión definida por el número de aciertos del producto sobre el total muestreado.

## Resultados

### Corrientes

El total de polígonos de cambio analizados en la muestra fue de 304, de los cuales aproximadamente el 70% correspondían a los estratos Pinus C3 y Eucalyptus C3 (Tabla 1). Los resultados de precisión global y por estrato se resumen en la Tabla 1. El proceso de evaluación de la precisión del producto, evidenció que del total muestral analizado, 251 polígonos de pérdida de cobertura forestal en 2019 fueron detectados correctamente, resultando en una precisión global del 82,57 %. En cuanto a los estratos más numerosos, estos se corresponden con las categorías más importantes en las cuales se esperan cambios (cosechas), siendo su precisión de 82% y 85,33% para Pinus C3 y Eucalyptus C3, respectivamente.

<b>Tabla 1.</b> Precisión global y según estrato de polígonos de cambio del producto de Hansen <i>et al.</i> en la provincia de Corrientes				
Estrato	Cambio No verificado	Cambio Verificado	Tamaño de muestra por estrato	Precisión (%)
Eucalyptus C1	1	9	10	90,00
Eucalyptus C2	8	20	28	71,43
Eucalyptus C3	11	64	75	85,33
Pinus_C1	0	1	1	100,00
Pinus C2	0	1	1	100,00
Pinus C3	27	123	150	82,00
Otros C1	0	1	1	100,00
Otros C3	1	1	2	50,00
Sin Datos	5	31	36	86,11
<b>Precisión Global</b>	<b>53</b>	<b>251</b>	<b>304</b>	<b>82,57</b>

Con respecto al intervalo de confianza calculado en RStudio, este determina que, con una confianza del 95%, el valor verdadero de la precisión global del producto de pérdida en Corrientes se encuentra entre el rango de 77,72% y 86,56 %.

### Entre Ríos

Un total de 193 polígonos conformaron la muestra a verificar en Entre Ríos. Como se puede observar en la Tabla 2, los estratos muestreados más numerosos fueron “Eucalyptus C3”, “Pinus C3” y “Sin Datos”, siendo su precisión por estrato de 91.43%, 69.23% y 84.38%, respectivamente. La precisión global resultante del proceso de verificación fue de 85,49%.

**Tabla 2.** Precisión global y según estrato de polígonos de cambio del producto de Hansen *et al.* en la provincia de Entre Ríos

Estrato	Cambio No verificado	Cambio Verificado	Tamaño de muestra por estrato	Precisión (%)
Eucalyptus C1	1	2	3	66,67
Eucalyptus C2	2	19	21	90,48
Eucalyptus C3	6	64	70	91,43
Pinus C1	0	1	1	100,00
Pinus C2	1	0	1	0,00
Pinus C3	8	18	26	69,23
Otros C3	0	7	7	100,00
Sin Datos	10	54	64	84,38
<b>Precisión Global</b>	<b>28</b>	<b>165</b>	<b>193</b>	<b>85,49</b>

El cálculo del intervalo de confianza indica que, con un nivel de confianza del 95%, la precisión global del producto de pérdida de cobertura forestal en Entre Ríos se encuentra en un rango entre 79,54% y 89,99%.

### Misiones

Los resultados de la evaluación de la precisión en Misiones se presentan en la Tabla 3. Se verificaron un total de 260 polígonos, de los cuales 213 fueron correctamente clasificados como pérdida de cobertura forestal por el producto, resultando en una precisión global de 81,92%. En esta provincia, el estrato más numeroso fue Pinus C3, abarcando aproximadamente un 65% de la muestra y siendo su precisión de 84,21%. El segundo estrato más numeroso fue el de Otros C3, conformado principalmente por los géneros Araucaria y Grevillea. La precisión en este estrato fue de 80,65%.

**Tabla 3.** Precisión global y según estrato de polígonos de cambio del producto de Hansen *et al.* en la provincia de Misiones

Estrato	Cambio No verificado	Cambio Verificado	Tamaño de muestra por estrato	Precisión (%)
Eucalyptus C2	0	2	2	100,00
Eucalyptus C3	1	12	13	92,31
Pinus C1	1	1	2	50,00
Pinus C2	7	5	12	41,67
Pinus C3	27	144	171	84,21
Otros C2	0	1	1	100,00
Otros C3	6	25	31	80,65
Sin Datos	5	23	28	82,14
<b>Precisión Global</b>	<b>47</b>	<b>213</b>	<b>260</b>	<b>81,92</b>

De acuerdo al cálculo del intervalo de confianza del 95%, la precisión global del producto GFC en la detección de cosecha en plantaciones forestales de Misiones se encuentra entre valores de 76,58% y 86,30%.

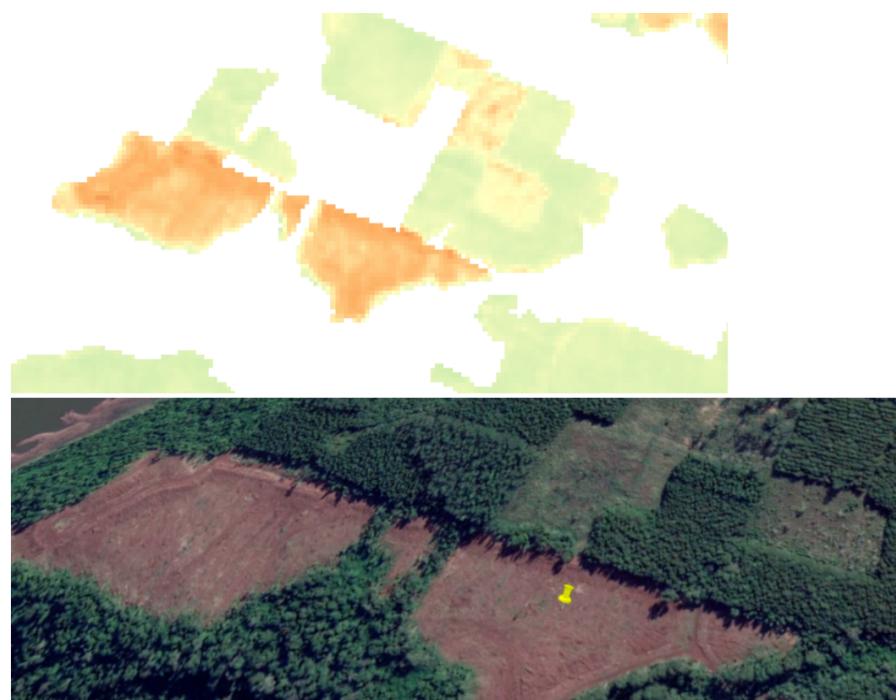
## Discusión

En términos generales, la evaluación de la precisión del producto GFC no evidenció resultados contrastantes entre las provincias de Misiones, Corrientes y Entre Ríos, siendo los valores de precisión global superiores al 80% en las tres provincias. La interpretación visual de las imágenes satelitales permitió identificar dos fuentes principales de sesgo del producto. Una de ellas corresponde al retraso en la detección de la pérdida de cobertura forestal, es decir, si bien el cambio por cosecha fue detectado correctamente en términos de localización y extensión, este ocurrió previo al 2019, año en el que el producto reportó el cambio. En adición a esto, se observó que el producto en muchos casos es sensible al cambio generado por el raleo de macizos forestales, identificando pérdida de cobertura forestal en las plantaciones en las que se realiza este manejo. Esto indicaría que el producto tiene la capacidad de detectar cambios más sutiles que la remoción total de cobertura forestal por cosecha. La definición de pérdida forestal de Hansen *et al.* (2013) se corresponde con un evento de reemplazo de un stand de bosque, o el cambio de un estado de “Bosque” a uno de “No bosque”. De acuerdo a estos autores, la degradación de bosques, como la remoción selectiva que no conduce a un estado de “No bosque”, no estaba contemplada dentro de la caracterización del cambio en las versiones iniciales del producto. Sin embargo, en la actualización más reciente del producto, la versión 1.7, se realizaron modificaciones con el objetivo de mejorar la detección de pérdida forestal global. Entre ellas se encuentra la mejora del producto en la detección de modificaciones en la cobertura debido a la remoción

selectiva de árboles, lo cual podría conducir a una sobreestimación del área cosechada de plantaciones forestales. Es por ello que este producto se utilizará en forma complementaria con un mapa cambios generado a partir de índices de vegetación a una resolución espacial de 10 metros (Figuras 2 y 3), el cual permitirá precisar si se trata de una cosecha total o un raleo (Figura 4) así como el comienzo de una nueva rotación (Figura 5).



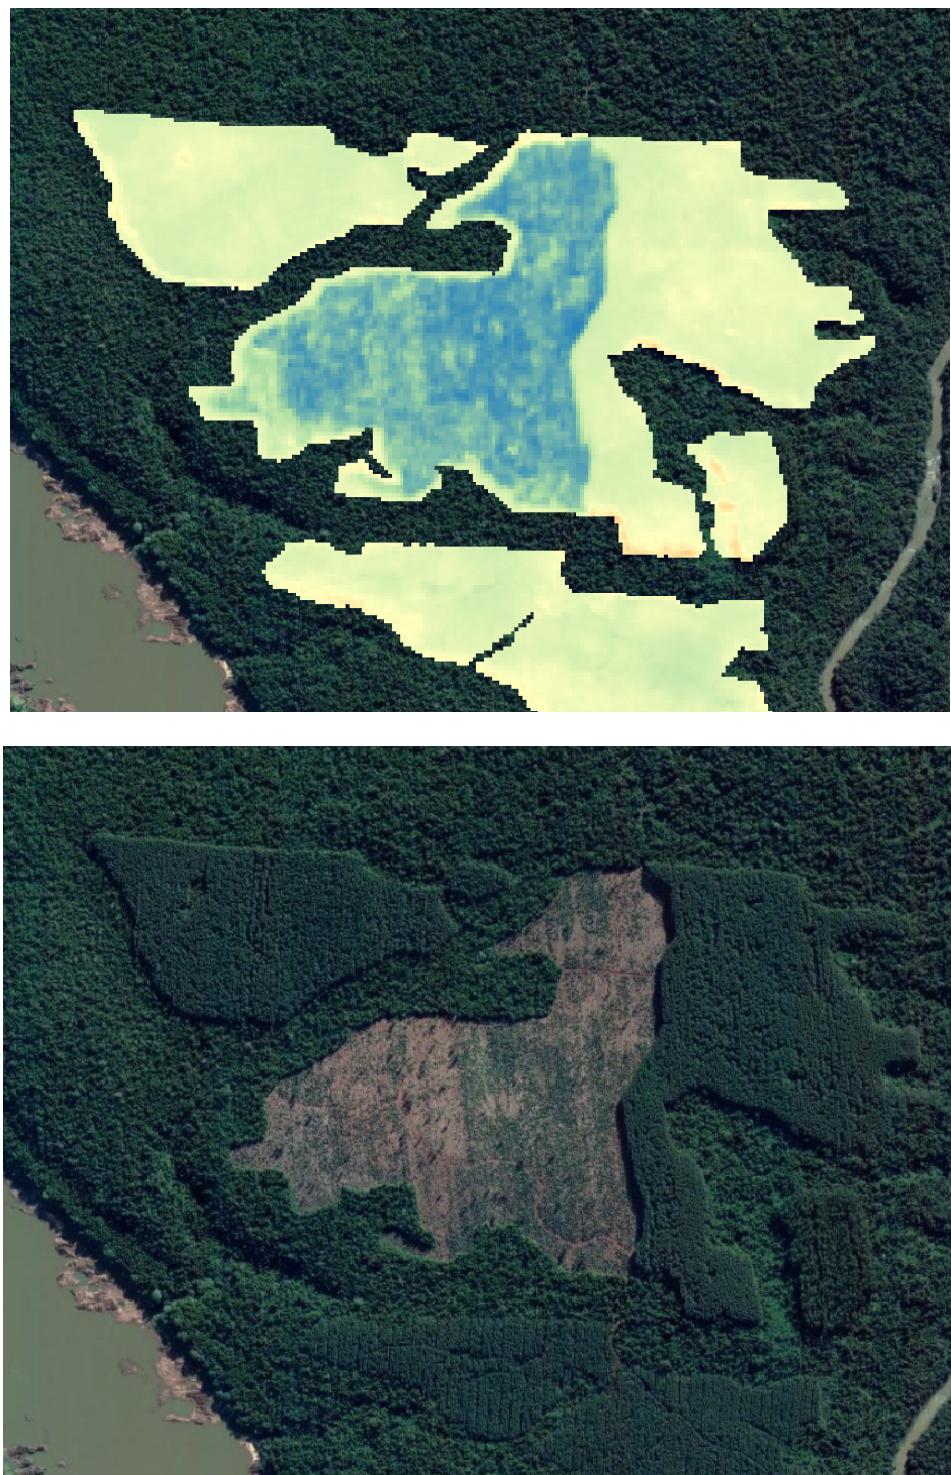
**Figura 2.** Mapa de índice de vegetación a escala regional. Imagen - NDVI (Septiembre 2020).



**Figura 3.** Mapa de índice de vegetación escala predial. Arriba: en tonos naranja se identifican áreas con pérdida de cobertura forestal. Abajo: detalle sobre la base de imagen de alta resolución espacial ( Google Earth).



**Figura 4.** Detección errónea de pérdida de cobertura en forestal en macizos sometidos a raleo sistemático durante el año 2019, en el departamento de Goya. Arriba: imagen Sentinel con fecha de enero de 2019. Abajo: imagen Sentinel con fecha de enero del año 2020. Con bordes negros se observan los polígonos de pérdida de cobertura forestal en 2019 del producto de Hansen et al.



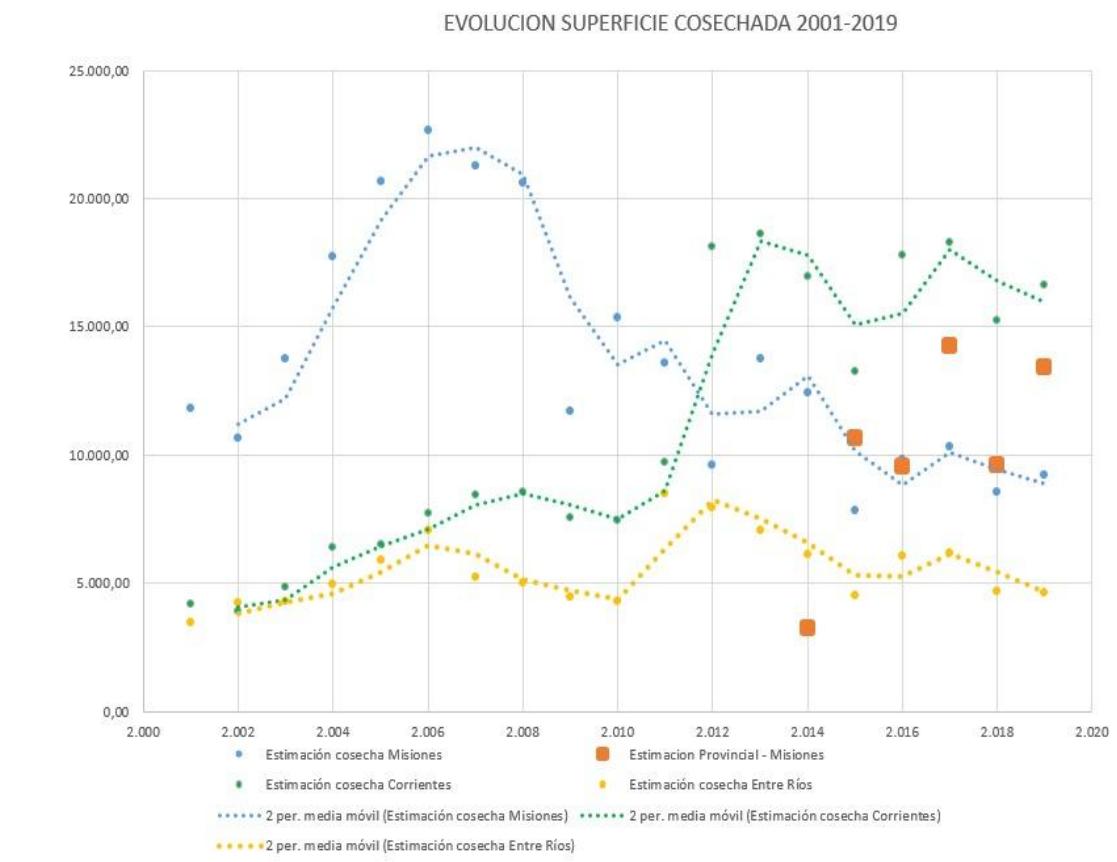
**Figura 5.** Mapa de índice de vegetación a escala predial. Arriba: en tonos azules se identifican áreas con ganancia de cobertura forestal. Abajo: detalle sobre la base de imagen de alta resolución espacial (Google Earth).

Por otra parte, la cobertura nubosa puede ser una fuente considerable de sesgo en la detección de cambio por parte del producto, ya que las nubes y sombras de nubes contaminan y alteran el valor los píxeles de las imágenes utilizadas al generar el producto (Arjasakusuma et al., 2018; Cunningham et al., 2019). Como consecuencia, el año del producto de pérdida de Hansen *et al.* puede determinar distintas precisiones en las

estimaciones anuales, dependiendo de la cantidad de imágenes con nubes empleadas al generar el producto.

## Conclusión

Los resultados obtenidos en este trabajo indican que la capa de pérdida de cobertura forestal del producto GFC es una herramienta útil para la identificación de los aprovechamientos que se producen en las plantaciones forestales de la región Nordeste de Argentina. Una vez identificados los aprovechamientos, mediante los datos de este producto es posible contabilizar el área cosechada de las plantaciones forestales en el período 2000-2019. Los datos de estas estimaciones se pueden observar en la Figura 6.



**Figura 6.** Evolución de la superficie cosechada en el período 2000-2019 en plantaciones forestales de Corrientes, Entre Ríos y Misiones.

## **Referencias**

- Ahl, D. E., Gower, S. T., Burrows, S. N., Shabanov, N. V., Myneni, R. B., & Knyazikhin, Y. (2006). Monitoring spring canopy phenology of a deciduous broadleaf forest using MODIS. *Remote Sensing of Environment, 104(1)*, 88-95. doi:10.1016/j.rse.2006.05.003
- Alvarez Amador, C. Manual de diseño experimentales para ingeniería agroforestal e ingeniería en zootecnia. Universidad de las Regiones Autónomas de la Costa Caribe Nicaragüense (URACCAN). 2018.
- Arjasakusuma, S., Kamal, M., Hafizt, M., & Forestriko, H. F. (2018). Local-scale accuracy assessment of vegetation cover change maps derived from Global Forest Change data, ClasLite, and supervised classifications: Case study at part of Riau Province, Indonesia. *Applied Geomatics, 10(3)*, 205-217. doi:10.1007/s12518-018-0226-2
- Asner, G. P. (2001). Cloud cover in Landsat observations of the Brazilian Amazon. *International Journal of Remote Sensing, 22(18)*, 3855-3862. doi:10.1080/01431160010006926

- Boca, T. y G. Rodríguez. 2012. Métodos estadísticos de la evaluación de la exactitud de productos derivados de sensores remotos. Asociación Argentina de Mecánica Computacional. Buenos Aires (Argentina): Instituto Nacional de Tecnología Agropecuaria.
- Cochran, W.G. 1977. Sampling Techniques; Third Edition; Wiley. New York.
- Cunningham, D., Cunningham, P., & Fagan, M. E. (2019). Identifying Biases in Global Tree Cover Products: A Case Study in Costa Rica. *Forests*, 10(10), 853. doi:10.3390/f10100853
- Galiatsatos, N., Donoghue, D. N. M., Watt, P., Bholanath, P., Pickering, J., Hansen, M. C., & Mahmood, A. R. J. (2020). An Assessment of Global Forest Change Datasets for National Forest Monitoring and Reporting. *Remote Sensing*, 12(11), 1790. doi:10.3390/rs12111790
- Gómez, C., White, J. C., & Wulder, M. A. (2016). Optical remotely sensed time series data for land cover classification: A review. *ISPRS Journal of Photogrammetry and Remote Sensing*, 116, 55-72. doi:10.1016/j.isprsjprs.2016.03.008
- Guindon, L., Bernier, P., Gauthier, S., Stinson, G., Villemaire, P., & Beaudoin, A. (2018). Missing forest cover gains in boreal forests explained. *Ecosphere*, 9(1). doi:10.1002/ecs2.2094
- Hall, R., Skakun, R., Arsenault, E., & Case, B. (2006). Modeling forest stand structure attributes using Landsat ETM data: Application to mapping of aboveground biomass and stand volume. *Forest Ecology and Management*, 225(1-3), 378-390. doi:10.1016/j.foreco.2006.01.014
- Hansen, M. C., Potapov, P. V., Moore, R., Hancher, M., Turubanova, S. A., Tyukavina, A., . . . Townshend, J. R. (2013). High-Resolution Global Maps of 21st-Century Forest Cover Change. *Science*, 342(6160), 850-853. doi:10.1126/science.1244693
- Hansen, M., Potapov, P., Margono, B., Stehman, S., Turubanova, S., & Tyukavina, A. (2014). Response to Comment on "High-resolution global maps of 21st-century forest cover change". *Science*, 344(6187), 981-981. doi:10.1126/science.1248817
- Hansen, M. C., Potapov, P. V., Goetz, S. J., Turubanova, S., Tyukavina, A., Krylov, A., . . . Egorov, A. (2016). Mapping tree height distributions in Sub-Saharan Africa using Landsat 7 and 8 data. *Remote Sensing of Environment*, 185, 221-232. doi:10.1016/j.rse.2016.02.023
- Harper, K. A., Macdonald, S. E., Burton, P. J., Chen, J., Brosofske, K. D., Saunders, S. C., . . . Esseen, P. (2005). Edge Influence on Forest Structure and Composition in Fragmented Landscapes. *Conservation Biology*, 19(3), 768-782. doi:10.1111/j.1523-1739.2005.00045.x
- Hojas-Gascon, L., Cerutti, P., Eva, H., Nasi, R., & Martius, C. (2015). Monitoring deforestation and forest degradation in the context of REDD : Lessons from Tanzania. doi:10.17528/cifor/005642
- Kangas, A., Astrup, R., Breidenbach, J., Fridman, J., Gobakken, T., Korhonen, K. T., . . . Olsson, H. (2018). Remote sensing and forest inventories in Nordic countries – roadmap for the future. *Scandinavian Journal of Forest Research*, 33(4), 397-412. doi:10.1080/02827581.2017.1416666

- Kennedy, R., Yang, Z., Gorelick, N., Braaten, J., Cavalcante, L., Cohen, W., & Healey, S. (2018). Implementation of the LandTrendr Algorithm on Google Earth Engine. *Remote Sensing*, 10(5), 691. doi:10.3390/rs10050691
- Li, A., Jiang, J., Bian, J., & Deng, W. (2012). Combining the matter element model with the associated function of probability transformation for multi-source remote sensing data classification in mountainous regions. *ISPRS Journal of Photogrammetry and Remote Sensing*, 67, 80-92. doi:10.1016/j.isprsjprs.2011.10.008
- Li, Y., Sulla-Menashe, D., Motesharrei, S., Song, X., Kalnay, E., Ying, Q., . . . Ma, Z. (2017). Inconsistent estimates of forest cover change in China between 2000 and 2013 from multiple datasets: Differences in parameters, spatial resolution, and definitions. *Scientific Reports*, 7(1). doi:10.1038/s41598-017-07732-5
- Lwin, K. K., Ota, T., Shimizu, K., & Mizoue, N. (2019). Assessing the Importance of Tree Cover Threshold for Forest Cover Mapping Derived from Global Forest Cover in Myanmar. *Forests*, 10(12), 1062. doi:10.3390/f10121062
- Mitchard, E.; Viergever, K.; Morel, V.; Tipper, R. Assessment of the Accuracy of University of Maryland (Hansen et al.) Forest Loss Data in 2 ICF Project Areas—Component of a Project that Tested an ICF Indicator Methodology, 2015
- Nguyen, T. H., Jones, S., Soto-Berelov, M., Haywood, A., & Hislop, S. (2019). Landsat Time-Series for Estimating Forest Aboveground Biomass and Its Dynamics across Space and Time: A Review. *Remote Sensing*, 12(1), 98. doi:10.3390/rs12010098
- Sannier, C., Mcroberts, R. E., & Fichet, L. (2016). Suitability of Global Forest Change data to report forest cover estimates at national level in Gabon. *Remote Sensing of Environment*, 173, 326-338. doi:10.1016/j.rse.2015.10.032
- Qiu, S., He, B., Zhu, Z., Liao, Z., & Quan, X. (2017). Improving Fmask cloud and cloud shadow detection in mountainous area for Landsats 4–8 images. *Remote Sensing of Environment*, 199, 107-119. doi:10.1016/j.rse.2017.07.002
- Trends.Earth. Conservation International. Available online at: <http://trends.earth>. 2018.
- Tropek, R., Sedla Ek, O., Beck, J., Keil, P., Musilova, Z., Imova, I., & Storch, D. (2014). Comment on "High-resolution global maps of 21st-century forest cover change". *Science*, 344(6187), 981-981. doi:10.1126/science.1248753
- Urbazaev, M., Thiel, C., Migliavacca, M., Reichstein, M., Rodriguez-Veiga, P., & Schmullius, C. (2016). Improved Multi-Sensor Satellite-Based Aboveground Biomass Estimation by Selecting Temporally Stable Forest Inventory Plots Using NDVI Time Series. *Forests*, 7(12), 169. doi:10.3390/f7080169
- Woodcock, C. E., Allen, R., Anderson, M., Belward, A., Bindschadler, R., Cohen, W., . . . Wynne, R. (2008). Free Access to Landsat Imagery. *Science*, 320(5879). doi:10.1126/science.320.5879.1011a
- Zhu, Z., & Woodcock, C. E. (2012). Object-based cloud and cloud shadow detection in Landsat imagery. *Remote Sensing of Environment*, 118, 83-94. doi:10.1016/j.rse.2011.10.028

## Anexo

El análisis de verificación de los polígonos de cosecha en R se realizó a partir del comando `table()`, para generar una tabla de contingencia y obtener la frecuencia de polígonos de pérdida de cobertura forestal correctamente detectados en cada estrato y a nivel global.

```
conteo_estrato <- table(datos$estrato, datos$cambio_verificado)
```

Para obtener el total de polígonos correctamente identificados por el producto se utilizó el comando `addmargins()`

```
total_estratos <- addmargins(conteo_estrato)
```

A partir de la precisión global estimada, se calculó el intervalo de confianza del 95%, para un nivel de significación de 0.05, usando la función `prop.test()`.

```
prop.test(total de aciertos, tamaño muestral ,alternative = "two.sided", conf.level = 0.95)
```

